UNIVERSIDAD CATÓLICA BOLIVIANA "SAN PABLO"
UNIDAD DE POSTGRADO
PROGRAMA: MAESTRÍA EN CIENCIA DE DATOS

TRABAJO FINAL MODULO
INTRODUCCIÓN A CIENCIA DE DATOS
"DESARROLLO DE UN MODELO DE PRONÓSTICO DE DEMANDA DE HARINA DE SOJA PARA APOYAR LA PLANIFICACIÓN DE LA PRODUCCIÓN EN SOCIEDAD AGRÍCOLA DEL VALLE S.R.L."

Presentado por:

Ariel Velasco Antezana

ZZ de octubre de 2026

CONTENIDO

1. Comprensión del Negocio ..... **¡Error! Marcador no definido.**
   1.1 Objetivos del Negocio 3
   1.2 Inventario de recursos, requisitos, supuestos y restricciones 4
   1.3 Plan de proyecto 4
2. Comprensión de los Datos 6
   2.1 Recolección de los datos 6
   2.2 Descripción de los datos 6
   2.3 Exploración de los datos 7
   2.4 Calidad de los datos 8
3. Preparación de los datos 9
   3.1 Selección de los datos 9
   3.2 Limpieza de los datos 9
   3.3 Estructuración de los datos 10
   3.4 Integración de los datos 10
4. Modelado 11
   4.1 Selección de técnica de Modelado 11
   4.2 Generación del plan de prueba 11
   4.3 Construcción del Modelo 11
   4.4 Evaluación del Modelo 12
5. Evaluación 14
   5.1 Evaluación de los resultados 14
   5.2 Revisión del proceso 15
   5.3 Determinar próximos pasos 16
6. Implementación 16
   6.1 Plan de Implantación 16
   6.2 Plan de monitoreo y mantención 18
7. Conclusiones 21
8. Bibliografía 23

1. Resumen Ejecutivo del Marco Híbrido

El Trabajo Final del modulo MCD-701 adopta un enfoque hibrido metodológico que combina la orientación estrategia de CRIPS-DM con las etapas técnicas del proceso OSEMN. CRIPS-DM(Cross Industry Standard Process for Data Mining) es un modelo de proceso independiente del sector y de la tecnología, que organiza los proyectos de minería de datos en seis fases: comprensión del negocio, comprensión de los datos, preparación de los datos, modelado, evaluación y despliegue (Chapman, y otros, 2000) (Wirth & Hipp, 2000). Su uso esta tan extendido que se lo considera el estándar de facto para este tipo de proyectos (Schröer, Kruse, & Gómez, 2021). OSEMN, por su parte, describe las tareas del científico de datos en orden aproximadamente cronológico: obtener(OBTAIN), depurar(SCRUB), explorar(EXPLORE), modelar(MODEL) e interpretar(INTERPRET) (Mason & Wiggins, 2010). Esta integración permite abordar de manera estructurada un problema empresarial mediante el análisis de datos, el desarrollo de un modelo predictivo y la presentación de resultados orientados a la toma de decisiones.

En este proyecto, el enfoque se aplica al pronóstico de las ventas mensuales de harina de soja en Sociedad Agrícola del Valle S.R.L. (SAVAL S.R.L.), con el propósito de analizar los registros históricos y generar estimaciones que contribuyan a la planificación de la producción. Para ello, se utilizarán archivos Excel con información mensual correspondiente al período comprendido entre noviembre de 2007 y septiembre de 2026.

La metodología contempla la comprensión del problema empresarial, la obtención y preparación de los datos, el análisis exploratorio, el desarrollo y la evaluación de un modelo SARIMA (Box, Jenkins, Reinsel, & Ljung, 2015), así como su comparación con un método de referencia estaciona, el pronostico estacional ingenuo, que repite el valor observado en el mismo mes del año anterior (Hyndman & Athanasopoulos, Forecasting: Principles and practice, 2021). Finalmente, se implementará un prototipo de interfaz mediante Streamlit, que permitirá visualizar las ventas históricas, consultar pronósticos y examinar mántricas de evaluación. La inclusión de esta fase de despliegue es relevante, porque buena parte de los estudios aplican CRIPS-DM no la contemplan (Schröer, Kruse, & Gómez, 2021).

El proyecto se centrará en evaluar la capacidad del modelo para pronosticar las ventas futuras y en determinar su utilidad potencial como herramienta de apoyo a la planificación de la producción, considerando las limitaciones derivadas de la calidad de los datos y de los cambios que puedan producirse en las condiciones del mercado.

Capa de Gestión (CRISP-DM)	Pipeline Técnico (OSEMN)	Herramientas & Entregables del Curso
1. Comprensión del Negocio	Definición del problema y del objetivo predictivo.	Planteamiento del problema, objetivo general, objetivos específicos y definición de indicadores para evaluar el pronóstico.
2. Comprensión de Datos	O — Obtain (Obtener)	Recopilación de archivos Excel con registros mensuales de ventas desde noviembre 2007 hasta septiembre de 2026. Identificación de variables, revisión de formatos y definición del periodo de análisis.

3. Preparación de Datos	S — Scrub(Depurar) & E — Explore	Python, pandas y Google colab para consolidar los archivos Excel, verificar fechas, valores faltantes y duplicados, analizar tendencias y explorar posibles patrones estacionales mediante estadísticas y visualizaciones.
4. Modelado y Evaluación	M — Model (Modelar)	Python y la biblioteca statsmodels para desarrollar un modelo SARIMA y compararlo con un pronóstico estacional ingenuo. Evaluación mediante métricas de error, como MAE y RMSE, utilizando datos de prueba separados cronológicamente.
5. Interpretación, visualización y despliegue del modelo	N — interpret (Interpretar)	Streamlit y Matplotlib para desarrollar una interfaz interactiva que permita visualizar las ventas históricas, consultar los pronósticos generados por SARIMA y presentar métricas de evaluación. Interpretación de resultados, limitaciones y utilidad potencial para apoyar la planificación de la producción.

1. Comprensión del Negocio

1.1 Objetivos del Negocio

El objetivo del negocio es desarrollar un modelo de pronóstico de ventas mensuales de harina de soja en Sociedad Agricola del Valle S.R.L(SAVAL S.R.L.)., utilizando registros históricos comprendidos entre noviembre de 2007 y septiembre de 2026, con la finalidad de generar estimaciones que sirvan como apoyo para la planificación de la producción.

Actualmente, la empresa dispone de registros de ventas organizados en Excel separados por año. Esta información permite estudiar el comportamiento histórico de las ventas, identificar tendencias y posibles patrones estacionales, y evaluar técnicas de Ciencia de Datos para estimar ventas futuras. Entre ellas se considera el modelo SARIMA, que combina componentes autorregresivos, de diferenciación y de medias móviles con un componente estacional y es una técnica clásica para series mensuales con patrones repetitivos (Box, Jenkins, Reinsel, & Ljung, 2015).

Como resultado, se busca desarrollar un modelo de pronóstico evaluado mediante métricas de error y un prototipo de interfaz web interactiva que facilite la visualización de los registros históricos, la consulta de las estimaciones y la interpretación de los resultados.

Los objetivos específicos son:

- Consolidar y analizar los registros mensuales de ventas disponibles.
- Identificar tendencias, variaciones y posibles patrones, variaciones y posibles patrones estacionales en las ventas.
- Desarrollar y comparar técnicas de pronostico apropiadas para los datos disponibles.

- Evaluar el desempeño del modelo mediante métricas de error.
- Implementar una interfaz interactiva para visualizar las ventas históricas y consultar pronósticos.

1.2 Inventario de recursos, requisitos, supuestos y restricciones

Datos y recursos

Se dispone de registros históricos de ventas mensuales de harina de soja correspondiente al periodo comprendido entre 2007 y septiembre 2026, organizados en archivos Excel independientes por año. Estos archivos constituyen la fuente principal de información para el proyecto.

Se realizará un proceso de consolidación de los archivos en una única estructura de datos cronológica, verificando la consistencia de las fechas, las unidades de medida, los valores registrados y continuidad de la serie mensual.

Requisitos

El proyecto requiere disponer de los archivos históricos de ventas, identificar las columnas relevantes y establecer una variable objetivo que represente la cantidad vendida por mes. También será necesario preparar los datos para el análisis exploratorio, seleccionar técnicas de pronóstico, evaluar los resultados y desarrollar una interfaz web para presentar las estimaciones.

Supuestos

Se considera que los registros proporcionados corresponden a las ventas efectivamente registradas por la empresa y que los valores pueden compararse entre periodos. Se verificará que las unidades de medida y los criterios de registro sean consistentes a lo largo de los años. Asimismo, se evaluará si los patrones históricos aportan información útil para pronosticar las ventas futuras, sin asumir que se mantendrán necesariamente en el futuro.

Restricciones

La calidad y precisión de los resultados dependerán de la integridad, continuidad y consistencia de los registros históricos. Los cambios en las condiciones comerciales, los precios, la disponibilidad del producto o el comportamiento del mercado podrían afectar las ventas futuras y limitar la capacidad predictiva del modelo.

El análisis se centrará en las ventas mensuales, por lo que los resultados no necesariamente representaran la demanda real cuando existan restricciones de inventario o ventas no concretadas.

Herramientas tecnológicas

Para el desarrollo se usará Python como lenguaje de programación, Pandas y NumPy para la manipulación de datos, Matplotlib o Plotly para la visualización, Scikit-learn y otra biblioteca compatible con la técnica de pronostico seleccionada para el modelado y la evaluación, Google Colab para la experimentación y Streamlit para desarrollar la interfaz interactiva.

1.3 Plan de proyecto

		1	2	3	4	5	6	7
1.	Comprensión del Negocio	■						
1.1	Objetivos del Negocio	■						
1.2	Inventario de recursos, requisitos, supuestos y restricciones	■						

1.3	Plan de proyecto	■						
2.	Comprensión de los Datos	■	■	■				
2.1	Recolección de los datos	■	■					
2.2	Descripción de los datos		■					
2.3	Exploración de los datos		■	■				
2.4	Calidad de los datos		■	■				
3.	Preparación de los datos			■	■			
3.1	Selección de los datos			■				
3.2	Limpieza de los datos			■	■			
3.3	Estructuración de los datos				■			
3.4	Integración de los datos				■			
4.	Modelado				■	■	■	
4.1	Selección de técnica de Modelado				■	■		
4.2	Generación del plan de prueba					■		
4.3	Construcción del Modelo					■		
4.4	Evaluación del Modelo					■	■	
5.	Evaluación						■	■
5.1	Evaluación de los resultados						■	
5.2	Revisión del proceso						■	■
5.3	Determinar próximos pasos							■
6.	Implementación						■	■
6.1	Plan de Implantación						■	■
6.2	Plan de monitoreo y mantención							■

1.4 Definición de Indicadores (KPIs)

Se definirán indicadores que permitan describir el comportamiento histórico de las ventas mensuales de harina de soja y evaluar el desempeño del modelo de pronostico. Estos indicadores servirán para comprender la evolución de las ventas y determinar si las estimaciones generadas pueden aportar información útil para la planificación de la producción.

Los principales indicadores descriptivos considerados serán:

- **Volumen de ventas mensual:** Cantidad total de harina de soja vendida en cada mes, expresada en la unidad de medida utilizada por la empresa.
- **Promedio de ventas mensuales:** Valor medio de las ventas registradas durante el periodo analizado.
- **Validación interanual:** Cambio porcentual de las ventas de un mes respecto al mismo mes del año anterior.

Para evaluar el desempeño del modelo se usarán las siguientes métricas de error, definidas en (Hyndman & Koehler, 2006):

- **Error absoluto medio (MAE):** Indicador de las diferencias absolutas entre las ventas reales y las pronosticadas.
- **Raíz del error cuadrático medio (RMSE):** Indicador que permite evaluar la magnitud de los errores y penaliza en mayor medida los errores grandes.
- **Error porcentual absoluto ponderado (WAPE) y sesgo:** El primero expresa error total como porcentaje de las ventas totales; el segundo indica si el modelo tiende a pronosticar de mas o de menos.

Los indicadores descriptivos se calcularán durante el análisis exploratorio, mientras que las métricas de error se utilizarán para evaluar el modelo SARIMA y compararlo con un pronostico estacional de referencia (Hyndman & Athanasopoulos, 2021), calculadas sobre datos de prueba separados cronológicamente de los de entrenamiento.

2. Comprensión de los Datos

2.1 Recolección de los datos

Los datos provienen de los registros históricos de ventas de harina de soja de Sociedad Agricola del Valle S.R.L. La información está organizada en 20 archivos Excel(.xls), uno por año, desde "Ventas 2.007.xls" hasta "Ventas 2.026.xls", que cubren de noviembre de 2007 a septiembre de 2026. Cada archivo registra una venta por fila, con las columnas Fecha, Cliente, Nro. Nota, Cant. Bolsas, Peso y Monto (en algunos años también el precio por bolsa).

El procedimiento de recolección fue:

1. Reunir los 20 archivos en una carpeta de trabajo (Google Drive) y leerlos desde Python con pandas.
2. Detectar automáticamente la fila de encabezado de cada archivo (la que contiene "Fecha"), porque la tabla no empieza en la misma fila en todos los casos.
3. Estandarizar los nombres de columnas entre años (por ejemplo, Monto y Bs. Pasan a monto) y descartar columnas vacías.
4. Consolidar todo en una única tabla cronológica: 8.847 filas crudas en total.

La información se usa exclusivamente para los objetivos del proyecto, respetando las condiciones de acceso y confidencialidad acordadas con la empresa. Por ello, esta documentación no reproduce nombres de clientes.

2.2 Descripción de los datos

Ámbito geográfico: El estudio se desarrolla en el contexto operativo de SAVAL, en Cochabamba. El alcance geográfico especifico de las ventas depende de la cobertura de los registros de la empresa, que no incluyen una variable de ubicación del cliente.

Periodo temporal: noviembre de 2007 a septiembre de 2026, con frecuencia mensual de agregación. El año 2007 solo contiene noviembre y diciembre, porque la empresa recién iniciaba operaciones.

Unidad de análisis: En los archivos originales, cada fila es una venta (una nota de venta). Para el modelado se agregan a un registro por mes.

Variables de los archivos originales:

Variable	Descripción	Unidad
Fecha	Fecha de la venta	fecha
cliente	Nombre del cliente	texto
nota	Numero de nota de venta	entero
bolsas	Cantidad de bolsas vendidas	bolsas (50 kg)
peso_kg	Peso vendido	kg
monto	Importe de la venta	Bs
precio_bolsa	Precio por bolsa (solo en algunos años)	Bs/bolsa

Variable objetivo: La cantidad mensual vendida de harina de soja, expresada en toneladas (peso en kg dividido por 1.000). Se eligió el peso y no el número de bolsas porque es la medida real: casi todas las bolsas

pesan 50 kg, pero hay excepciones. Para el usuario final el pronóstico se convierte en bolsas de 50 kg (1 t = 20 bolsas)

Variables auxiliares derivadas: Monto mensual, número de pedidos, número de clientes distintos, bolsas y precio medio por kg.

2.3 Exploración de los datos

Se construyo la serie mensual sumando el peso de todas las ventas de cada mes, y se analizó con gráficos de la serie completa, gráficos de estacionalidad (una línea por año), estadísticos por año y una descomposición STL.

Nivel por año: La demanda pasa de unas 60 t mensuales en 2008-2009 a un régimen de 135-180 t desde 2012. Los años 2021 y 2023 son de mayor nivel, desde 2024 hay una caída marcada y una variabilidad mucho mayor.

Año	Media mensual (t)	Desv. Est. (t)	Mínimo (t)	Máximo (t)
2008	60,6	26,7	27,3	102,9
2009	59,9	23,5	26,3	98,0
2010	100,7	37,8	43,5	164,1
2011	112,8	21,0	80,3	158,4
2012	140,9	22,8	114,8	179,3
2013	154,8	13,7	133,3	183,8
2014	162,8	19,3	123,4	207,5
2015	135,4	27,7	99,6	168,8
2016	147,0	24,5	115,8	176,5
2017	150,4	20,2	116,5	186,6
2018	152,5	17,2	110,8	170,0
2019	145,2	22,2	100,8	197,2
2020	123,3	57,3	0,0	180,4
2021	181,8	30,8	141,6	229,8
2022	161,9	32,7	105,0	216,0
2023	172,0	21,3	127,0	196,6
2024	141,4	29,2	95,0	189,8
2025	112,4	42,4	58,0	191,6
2026 (ene–sep)	135,7	46,2	37,0	189,9

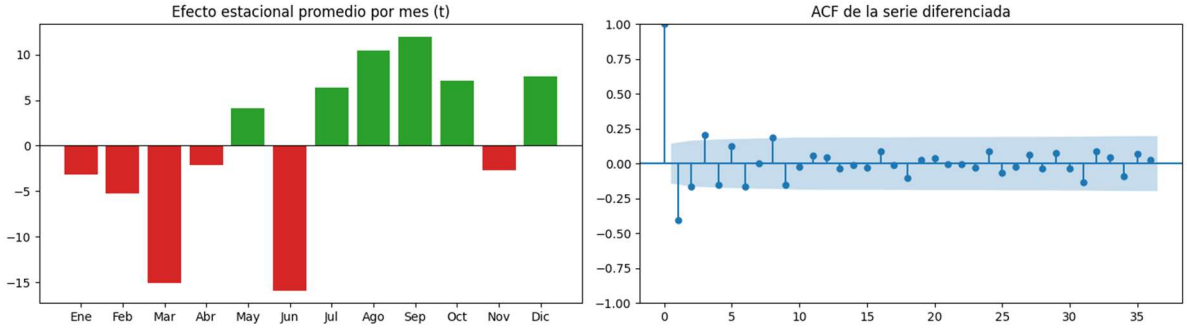
Estacionalidad: El promedio por mes del calendario (2008-2026) oscila entre 118 t(marzo) y 150 t (diciembre): febrero-abril y junio son los meses más bajos, y julio-diciembre los más altos. Sin embargo, la estacionalidad es débil:

- La fuerza estacional (STL, desde 2011, con COVID suavizado) es de 0,10 en una escala de 0 a 1
- Una prueba ANOVA comparando “nivel por año “contra “nivel por año + mes” da F = 3,02 con p = 0,0011: el efecto del mes es estadísticamente significativo, aunque modesto.
- El R^2 sube de 0,330 (solo año) a 0,444 (año + mes). Es decir, el nivel del año explica más que el mes.

Efecto estacional medio estimado por STL (toneladas respecto al nivel): enero -3,2; febrero -5,3; marzo -15,1; abril -2,1; junio -15,9; julio + 6,4; agosto +10,5; septiembre +12,0; octubre +7,2; noviembre -2,7; diciembre +7,6.

Conclusión de la exploración: La serie está dominada por cambios de nivel de un año a otro, con un patrón estacional real pero débil. Esto justifica probar modelos con componente estacional (SARIMA con s = 12) y compararlos contra referencias simples.

Figura 1. *Diagnóstico de la serie mensual de ventas (enero de 2011 a septiembre de 2026)*



Nota: Izquierda: efecto estacional promedio por mes, en toneladas respecto del nivel de la serie, estimado con descomposición STL; las barras verdes indican meses por encima del nivel y las rojas, por debajo. Derecha: función de autocorrelación (ACF) de la serie en primeras diferencias; la banda sombreada es el intervalo de confianza del 95%. Elaboración propia con datos de Sociedad Agrícola del Valle S.R.L.

2.4 Calidad de los datos

Se reviso la consistencia de los campos, los duplicados, las fechas y la coherencia entre peso y bolsas, y se cuadro cada archivo contra el total que trae el propio Excel. Hallazgos principales:

Problema	Detalle	Tratamiento
Filas de totales mezcladas con ventas	27 filas	Excluidas (se usaron para cuadrar cada archivo)
Ventas repetidas entre archivos	69 filas: el archivo 2026 repite ventas de nov–dic 2025 (3.897 bolsas)	Eliminada la copia del archivo posterior
Ventas repetidas dentro del mismo archivo	3 filas	Conservadas, porque el total del Excel las cuenta
Fechas con formato texto o dañadas	8 fechas ilegibles (por ejemplo "24/106/19")	Reparadas con el texto original y las fechas de ventas vecinas; una se aproximó con la fecha de la venta anterior
Fechas con año o mes erróneo	50 fechas sospechosas (año distinto al del archivo o fuera de orden)	13 corregidas por propuesta automática y 13 por corrección manual, verificadas contra las ventas vecinas
Valor no numérico en `monto`	1 fila ("Reintegro por precio")	Detectada; no afecta la variable objetivo
Peso distinto de bolsas × 50	24 filas	Se confía en el peso. Solo 2 filas con error evidente se corrigieron en bolsas
Cantidades nulas o ≤ 0	6 filas	Eliminadas
Mes sin ventas	abril de 2020 (0 t, efecto COVID)	Interpolado para el modelado

Complementos de la revisión de peso y bolsas: 8257 filas pesan exactamente 50 kg por bolsa. Las diferencias corresponden sobre todo a bolsas de 46 kg vendidas a un cliente en 2007-1009 y a algunas filas con error de digitación.

El cuadre contra los totales de cada Excel resulto exacto o con diferencias de pocas bolsas en casi todos los años. Excepciones: en 2012 el total de bolsas del Excel (29.212) no coincide con la suma de ventas (22.811), pero el total por peso si coincide con la suma, de modo que el error está en el total del archivo. En 2024 hay -60 bolsas y en 2026 +30 respecto del total por peso.

Tras esos controles, la tabla de ventas no tiene fechas fuera de su archivo, y las fechas de cada año van de principios de enero a fines de diciembre (2026 llega hasta el 30 de septiembre).

3. Preparación de los datos

3.1 Selección de los datos

De acuerdo con el objetivo (pronosticar la demanda mensual de harina de soja) se seleccionaron:

- **Variable principal:** peso vendido por mes en toneladas.
- **Periodo de la serie mensual:** enero de 2008 a septiembre de 2026(225 meses). Se excluyó 2007 porque solo tiene dos meses.
- **Periodo de modelado:** enero de 2011 a septiembre de 2026(189 meses). Los años 2008-2010 corresponden a la etapa de arranque de la empresa, con niveles de 60-100 t que no representan al régimen actual(110-180t).
- **Variables descartadas para el modelo:** cliente, numero de nota y archivo de origen, que sirven solo para depurar los datos.

3.2 Limpieza de los datos

Datos perdidos: El peso o las bolsas faltantes se completaron con la relación de 50 kg por bolsa. Las filas con cantidad <= 0 se eliminaron. El precio por bolsa, que no existe en todos los años, se reconstruyo como monto ÷ bolsas.

Valores atípicos: No se eliminó ningún valor atípico de forma automática. Se revisaron los 23 meses por debajo de 70t:

- Los de 2008 a 2010 reflejan el arranque de la empresa y se excluyen al empezar el modelado en 2011.
- Abril y mayo de 2020 (0 y 18,6 t) corresponden a la cuarentena por COVID-19. Se tratan como datos faltantes y se interpolan linealmente en la serie de modelado.
- Los meses bajos de 2025 y 2026 (por ejemplo, 58,0 t en julio de 2025 y 37,0 t en junio de 2026) tienen un número razonable de pedidos y se consideran reales, por lo que se conservan.

Como muestra la Figura 1, la caída de abril y mayo de 2020 es un hecho excepcional frente al resto de la serie, por lo que se reemplazó por una interpolación lineal entre los meses vecinos.

Figura 2. *Tratamiento de abril y mayo de 2020(COVID-19) en la serie mensual de ventas.*



Nota: Serie mensual de toneladas vendidas de enero de 2011 a septiembre 2026. La línea gris muestra la serie original, con la caída a 0 t en abril de 2020 y 18,6t en mayo, y la línea azul es la serie usada para modelar. Los puntos rojos son los dos meses reemplazados por interpolación lineal. Elaboración propia con datos de Sociedad Agrícola del Valle S.R.L.

Columnas adicionales y transformaciones.

- **Estandarización:** Nombres de columnas, nombres de clientes (espacios y mayúsculas) y fechas en formato único.
- **Conversión de unidades:** Toneladas = kg ÷ 1.000; bolsas = kg ÷ 50.
- **Variables derivadas por mes:** n_pedidos, n_clientes, precio_kg, bolsas y toneladas.
- No se aplicó discretización ni normalización, porque los modelos de series de tiempo utilizados trabajan con la variable en su escala original.

3.3 Estructuración de los datos

Resultado de la limpieza:

Tabla	Registros	Variables	Archivo
Ventas limpias (una fila por venta)	8.238	9: fecha, cliente, nota, bolsas, peso_kg, monto, precio_bolsa, precio_kg, archivo	ventas_limpio.csv
Serie mensual (2008-01 a 2026-09)	225	7: peso_kg, monto, n_pedidos, n_clientes, bolsas, toneladas, precio_kg	serie_mensual.csv
Serie de modelado (2011-01 a 2026-09)	189	1: toneladas (con abril-mayo de 2020 interpolado)	serie_modelo.csv

El peso total vendido en el periodo es de 30.341.480 kg(unas 30.342 t). El precio medio por kg paso de 2,55 Bs en 2007 a unos 5,2 Bs en septiembre de 20266.

3.4 Integración de los datos

No se usaron tablas externas. La única integración realizada fue la unión de los 20 archivos anuales en una sola tabla, con las columnas estandarizadas descritas en 2.1, y su agregación mensual.

4. Modelado

4.1 Selección de técnica de Modelado

El problema es de predicción de una serie de tiempo univariada con frecuencia mensual.
Se compararon varias técnicas, de la más simple a la más compleja:

1. **Modelos base(referencia):** ingenuo (repite el último mes), estacional ingenuo (repite el mismo mes del año anterior), promedio de los últimos 12 meses y promedio de todo el entrenamiento.
2. **Regresión lineal:** Con tendencia lineal y variables indicadoras de mes
3. **SARIMA:** Modelo autorregresivo integrado de medias móviles con componente estacional, s=12.

Se eligió SARIMA como técnica principal porque la serie tiene dependencia temporal y un patrón estacional significativo (ANNOVA, p=0,0011), aunque débil. Los modelos simples son indispensables como referencia: un modelo complejo solo se justifica si supera una regla trivial.

4.2 Generación del plan de prueba

Se usaron dos esquemas de evaluación, siempre respetando el orden cronológico:

- **División entrenamiento/prueba:** Entrenamiento de enero de 2011 a diciembre 2024(168) y prueba de enero de 2025 a septiembre de 2026(21 meses).
- **Validación móvil (Rolling origin):** 14 cortes cada 6 meses, desde diciembre de 2028 hasta junio de 2025. En cada corte se entrena con el pasado y se pronostican los siguientes 12 meses. Es mas robusta que una sola partición porque promedia el desempeño en distintos momentos de la serie.

4.3 Construcción del Modelo

Regresión lineal: Variable de tendencia t (meses desde 2011) mas 11 indicadoras de mes, estimada por mínimos cuadrados.

SARIMA: Se probo una cuadricula de 144 combinaciones ($p, q \in \{0,1,2\}$; $d \in \{0,1\}$; $P, D, Q \in \{0,1\}$; $S = 12$) y se ordenó por AIC. Los 8 mejores modelos quedaron prácticamente empatados (AIC entre 1.318,3 y 1.320,3) y todos comparten el componente estación (0,1,1,12). El mejor AIC fue (1,1,2)(0,1,1,12), con AIC = 1.318,33.

Como el AIC no distingue entre los modelos, se compararon candidatos en la validación móvil. El que mejor rindió fue **SARIMA** (1,0,2)(0,1,1,12), que se adoptó como modelo final. Ajustado con toda la serie de modelado, sus coeficientes son:

Parámetro	Coeficiente	Error estándar	p-valor
AE(1)	0,885	0,060	<0,001
MA(1)	-0,639	0,105	<0,001
MA(2)	-0,032	0,080	0,695
MA estacional(12)	-0,940	0,159	<0,001
σ^2	761,9	92,4	<0,001

El termino MA(2) no es significativo; el resto si lo es. La prueba de Ljung-Box sobre los residuos da p=0,166(12 rezagos) y p = 0,779 (24 rezagos), por encima de 0,05: los residuos no muestran autocorrelación pendiente.

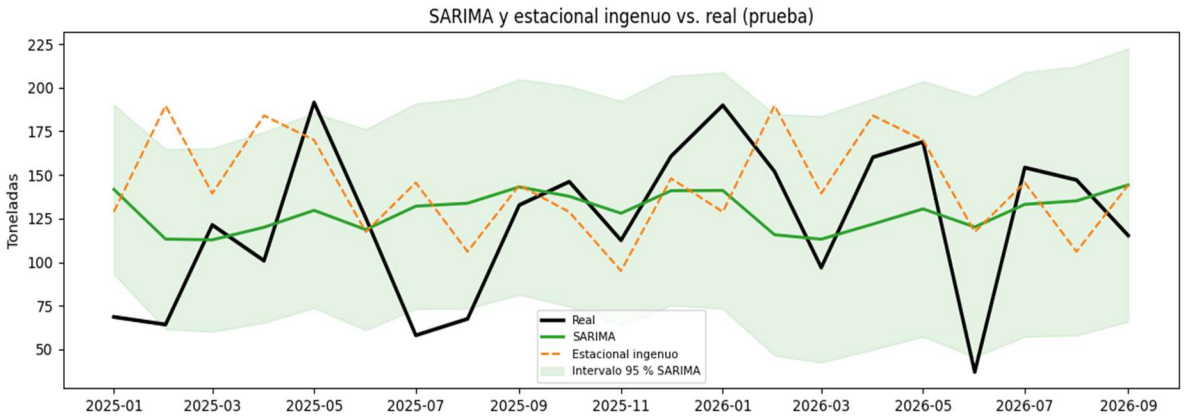
4.4 Evaluación del Modelo

Resultados en la prueba (enero 2025 – septiembre 2026, 21 meses):

Modelo	MAE(t)	RMSE(t)	WAPE (%)	Sesgo (%)
SARIMA	35,06	42,54	29,64	-5,28
Promedios últimos 12 meses (*)	36,42	43,89	29,76	-5,23
Ingenuo (último mes)	39,05	50,38	31,90	−20,87
Estacional ingenuo (mismo mes, año anterior)	39,39	50,62	32,18	−17,54
Promedio de todo el entrenamiento	39,76	51,49	32,48	−22,62
Regresión lineal	47,10	60,14	38,48	−35,26

Como muestra la Figura 3, el estacional ingenuo reproduce los picos y valles del año anterior, pero con frecuencia no coinciden con los reales; por ejemplo, anticipa un máximo en febrero de 2025, cuando las ventas fueron bajas. SARIMA, en cambio, sigue el nivel medio de las ventas con una trayectoria más suave y se equivoca menos en promedio, aunque no alcanza los picos ni los mínimos extremos, como el de junio de 2026.

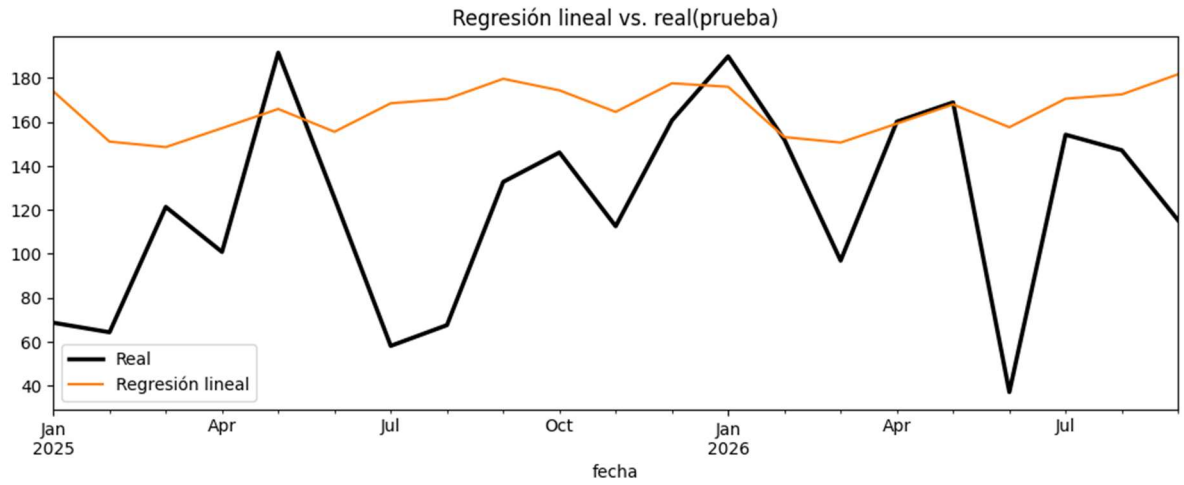
Figura 3. *Pronóstico de SARIMA y del estacional ingenuo frente a las ventas reales en el periodo de prueba.*



Nota. Periodo de prueba: enero de 2025 a septiembre de 2026 (21 meses). El estacional ingenuo repite el valor del mismo mes del año anterior. SARIMA corresponde al modelo (1,1,2)(0,1,1,12) y la banda sombreada es su intervalo de predicción del 95 %. Elaboración propia con datos de Sociedad Agrícola del Valle S.R.L.

Como muestra la Figura 4, la regresión lineal pronostica ventas de 150 a 180 t durante casi todo el periodo, muy por encima de lo observado. Esto se debe a que extrapola la tendencia de crecimiento de los años de entrenamiento, que la serie ya no sigue, y explica su sesgo de −35,26 % y su MAE de 47,10 t, los más altos entre los modelos evaluados.

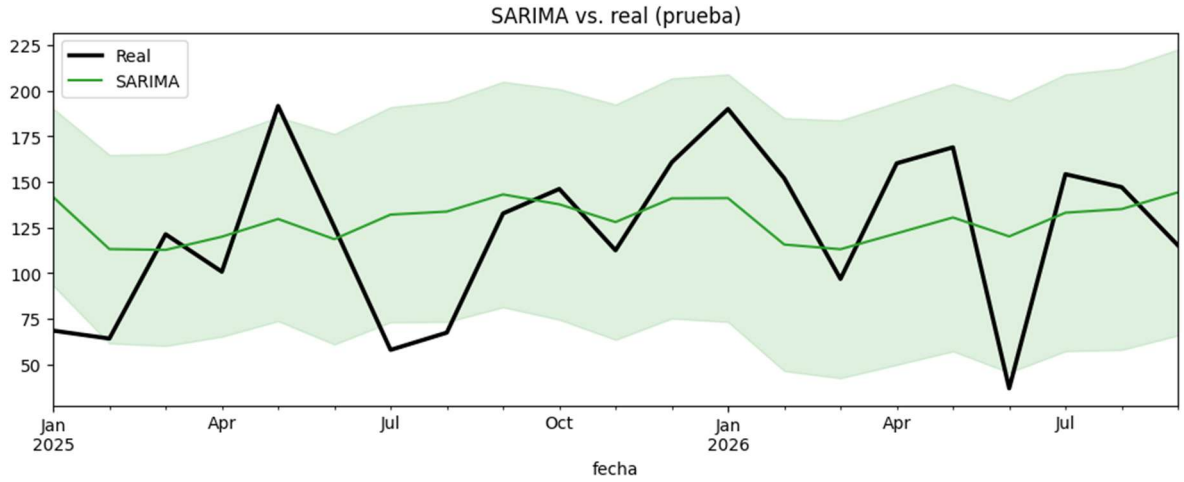
Figura 4. *Pronóstico de la regresión lineal frente a las ventas reales en el periodo de prueba.*



Nota. Periodo de prueba: enero de 2025 a septiembre de 2026 (21 meses). El modelo incluye una tendencia lineal y variables indicadoras de mes, y fue estimado con datos de enero de 2011 a diciembre de 2024. Elaboración propia con datos de Sociedad Agrícola del Valle S.R.L.

Como muestra la Figura 5, el pronóstico de SARIMA sigue el nivel medio de las ventas, pero no alcanza los picos de mayo de 2025 y enero de 2026 ni el mínimo de junio de 2026. Casi todos los valores reales caen dentro del intervalo del 95 %.

Figura 5*. Pronóstico de SARIMA frente a las ventas reales en el periodo de prueba.*



Nota. Periodo de prueba: enero de 2025 a septiembre de 2026 (21 meses). Modelo SARIMA (1,1,2)(0,1,1,12), estimado con datos de enero de 2011 a diciembre de 2024. La banda sombreada es el intervalo de predicción del 95 %. Elaboración propia con datos de Sociedad Agrícola del Valle S.R.L.

Lectura de los resultados:

- SARIMA reduce el MAE en un 11% y el RMSE en un 16% respecto del estacional ingenuo, el punto de comparación estándar para series con estacionalidad.
- Todos los modelos pronostican de más (sesgo negativo), porque las ventas bajaron en 2025-2026 respecto de los años de entrenamiento. La regresión lineal es la peor, porque extrapola una tendencia de crecimiento que la serie ya no tiene.

Validación móvil (14 cortes, horizonte de 12 meses):

Modelo	MAE (t)	RMSE (t)	WAPE (%)	Sesgo (%)
SARIMA (1,0,2) (0,1,1,12)	**27,82**	**34,34**	19,29	−3,74
SARIMA (0,1,2)(0,1,1,12)	28,79	35,13	19,95	−6,72
Promedio 12 meses + efecto estacional	29,08	35,38	20,13	−4,75
Promedio 12 meses	29,10	35,25	20,29	−4,75

SARIMA (1,0,2) (0,1,1,12) obtiene el menor error, pero su ventaja sobre el promedio de 12 meses con efecto estacional es pequeña (cerca de 4% en MAE). El error varía mucho según el corte: de 15 t(2018) a 49 t (2024)

5. Evaluación

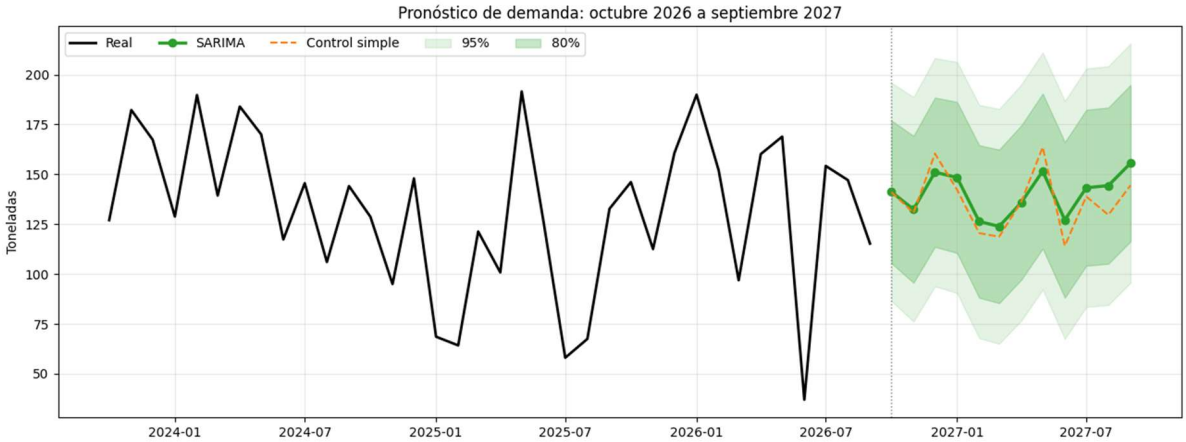
5.1 Evaluación de los resultados

Pronostico final: octubre de 2026 a septiembre de 2027. El modelo SARIMA (1,0,2)(0,1,1,12), ajustado con la serie 2011-septiembre 2026, proyecta un total de 1.681 t (33.621 bolsas de 50 kg) para los 12 meses.

Mes	Pronóstico (t)	Intervalo 80 % (t)	Pronóstico (bolsas)	Control simple (t)
oct 2026	141,2	105,4 – 176,9	2.824	141,1
nov 2026	132,4	95,6 – 169,3	2.649	130,7
dic 2026	151,1	113,6 – 188,5	3.021	160,4
ene 2027	148,4	110,5 – 186,3	2.968	142,3
feb 2027	126,3	88,1 – 164,6	2.527	120,5
mar 2027	123,9	85,4 – 162,4	2.478	118,7
abr 2027	135,8	97,1 – 174,5	2.716	136,3
may 2027	151,6	112,8 – 190,5	3.033	163,6
jun 2027	127,1	88,1 – 166,1	2.542	114,1
jul 2027	143,2	104,2 – 182,3	2.865	138,9
ago 2027	144,3	105,2 – 183,5	2.887	129,7
sep 2027	155,5	116,3 – 194,8	3.111	144,5

Como muestra la Figura 6, el modelo proyecta ventas de entre 124 y 156 t mensuales para octubre de 2026 a septiembre de 2027, con un total de 1.681 t (33.621 bolsas de 50 kg). El pronóstico se mantiene cerca del control simple en casi todos los meses, y los intervalos del 80 % y del 95 % indican la incertidumbre que debe considerarse al planificar.

***Figura 6**. Pronóstico de ventas de harina de soja para octubre de 2026 a septiembre de 2027.*



Nota. La línea negra muestra las ventas reales de octubre de 2023 a septiembre de 2026. El pronostico corresponde al modelo SARIMA(1,0,2)(0,1,1,12), estimado con datos de enero de 2011 a septiembre de 2026. Las bandas sombreadas son los intervalos de predicción del 80% y del 95%. El control simple es el promedio de los últimos 12 meses ajustado por el efecto estacional medio. Elaboración propia con datos de Sociedad Agrícola del Valle S.R.L.

El "control simple" es el promedio de los últimos 12 meses ajustado por el efecto estacional medio, sirve para comprobar que el pronóstico no se aleje de una referencia razonable. Los intervalos del95% están disponibles en el notebook.

Interpretación para SAVAL:

- El error típico es de unas 28 t por mes en validación móvil (cerca de 20% de las ventas) y de unas 35t en la prueba reciente. El pronóstico sirve para planificar el volumen aproximado y los niveles de inventario, pero no para fijar cantidades exactas por mes.
- Se recomienda usar el intervalo del 80% como rango de planificación y no solo el valor puntual: el ancho del intervalo es de unas ± 36 t.
- La mejora de SARIMA frente a las reglas simples es real pero modesta, coherente con la débil estacionalidad (0,10). Lo que más mueve la demanda son los cambios de nivel de un año a otro, que ningún modelo histórico puede anticipar por si solo.
- Desde 2025 la variabilidad es mayor (desviación estándar de 42-46 t) y el nivel más bajo, así que el pronóstico se debe revisar cada es con datos nuevos.

El modelo entrenado, la serie y la configuración se guardaron en la carpeta app_pronostico (modelo_sarima.pkl, serie_modelo.csv, config.json) para usarlos en una aplicación.

5.2 Revisión del proceso

El proceso siguió un orden coherente: limpieza y cuadre de datos, exploración modelos base, modelos candidatos, validación móvil y pronostico. Elementos que mejoraron el resultado:

- **Cuadre de cada archivo contra su total:** Permitió detectar duplicados entre archivos, fechas erróneas y un total mal calculado den 2012.
- **Interpolación del periodo COVID** y recorte de la etapa de arranque (2008-2010).
- **Validación móvil:** la partición única de 221 meses daba una ventaja de SARIMA sobre los modelos simples que cambia según el momento; con 14 cortes el desempeño es más estable.
- **Cambio del modelo final** de (1,1,2) a (1,0,2) con base en la validación móvil y no solo en el AIC.

Puntos que deben corregirse o aclararse antes de dar el proyecto por cerrado:

1. **Error en "Promedio últimos 12 meses"** (sección 11 del notebook): el código usa "train.iloc[-12].mean()", que toma un único valor (enero de 2024) en vez de train.iloc[-12:].mean(). Hay que corregirlo y volver a ejecutar las tablas de comparación.
2. **Estacional ingenuo fuera de la validación móvil:** la función "f_estacional" está definida pero no se incluyó en el diccionario de modelos, por lo que la evidencia más sólida del proyecto no lo compara. Conviene agregarlo.
3. **Modelos de regresión sin resultados en la validación móvil:** fallaron por un "NameError "(la función se define como "diseño" y se llama "disenio").
4. **Estacional ingenuo en la prueba de 21 meses:** Repite los últimos 12 meses de 2024 tambien para 2026, de modo que esta en desventaja frente a una versión que se actualiza cada año.
5. **Columna "WAPE" de la primera tabla de modelos base:** En realidad era el sesgo. La versión corregida (celda 14) calcula el WAPE con el error absoluto.
6. **Coeficiente estacional no invertible en el SARIMA de la prueba:** El termino MA estacional del modelo (1,1,2)(0,1,1,12) quedo en -1,0 con error estándar de 1.258, señal de sobre diferenciación estacional. En el modelo final el coeficiente es -0,94 con error estándar de 0,16, aunque sigue muy cerca de -1.
7. **Mes atípico de junio de 2026(37 t, 14 pedidos):** Se conservó como dato real; conviene confirmarlo con la empresa.

5.3 Determinar próximos pasos

Los resultados son satisfactorios para un uso de planificación: SARIMA supera de forma consistente a los modelos de referencia, aunque con margen moderado. Se recomienda:

1. Hacer una iteración corta de ajuste con los puntos 1 a 4 de 5.2, y volver a confirmar la comparación contra el estacional ingenuo y el promedio de 12 meses.
2. Comparar con al menos un modelo adicional y probar un modelo con variables externas, como el precio por kg, que subió con fuerza en la serie.
3. Reentrenar el modelo cada mes con ventas nuevas y comparar el pronóstico con lo real para detectar a tiempo cambios de nivel.
4. Validar con el personal de ventas los meses atípicos y los cambios de nivel de 2024-2026, que podrían explicar parte del error.
5. Poner el modelo en uso mediante la aplicación prevista en la carpeta, mostrando el rango del 80% junto con el valor central.

6. Implementación

6.1 Plan de Implantación

Se tiene planificado automatizar la obtención de datos, incorporando cada mes las ventas recién cerradas a la serie histórica, para reentrenar el modelo con ellas y generar un nuevo pronóstico de los siguientes 12 meses. El procedimiento queda documentado en cinco pasos que se repiten en cada cierre de mes:

1. **Obtención de datos:** se agregan las ventas del mes al archivo Excel del año en curso, respetando la estructura actual (Fecha, Cliente, Nro. Nota, Cantidad de bolsas, Peso, Monto).
2. **Limpieza y validación:** se ejecuta el notebook de tratamiento, que unifica los archivos anuales, excluye las filas de totales, valida las fechas, elimina las ventas repetidas entre archivos y compara la suma de cada año con el total del archivo.

3. **Construcción de la serie:** se agrega el peso vendido por mes en toneladas (la unidad comparable entre años, ya que algunas ventas antiguas usan presentaciones de 46 kg) y se completan con cero los meses sin ventas.
4. **Pronóstico:** se aplica el modelo SARIMA$(1,0,2)(0,1,1)_{12}$, entrenado con datos desde 2011, que entrega el pronóstico con intervalos de confianza de 80% y 95%.
5. **Despliegue:** los resultados se publican en una aplicación web.

Para facilitar la adopción de estos hallazgos, los resultados del modelo se desplegarán de forma visual e interactiva en una aplicación web desarrollada con Streamlit. Esta plataforma permite consultar de manera dinámica el pronóstico de demanda en toneladas y en bolsas de 50 kg, el histórico por año, la estacionalidad mensual y el desempeño del modelo, ajustando el horizonte, el nivel del intervalo y la unidad, sin necesidad de interactuar con el código. Para el período de octubre de 2026 a septiembre de 2027, el modelo estima unas 1,681 toneladas (aproximadamente 33,600 bolsas de 50 kg), un 2.5% más que los 12 meses anteriores y un 25% más que el año calendario 2025, uno de los más bajos de la serie reciente (ver Figura 7).

Figura 7. *Pestaña "Pronóstico" de la aplicación:prónostico de octubre de octubre de 2026 a septiembre de 2027 con intervalo de confianza de 80%, en toneladas.*



Luego de cada descubrimiento, como un cambio en el nivel de demanda o en el patrón estacional, se creará un plan para difundir la información a través de este tablero a [las áreas de compras, producción y ventas]. El tablero sirve como herramienta base para planificar compras e inventario hasta alcanzar el comportamiento deseado de ventas. Para esa planificación se recomienda tomar el valor central como referencia, el máximo del intervalo de 80% como tope de seguridad para evitar faltantes, y el total del período por encima de cada mes aislado, por ser más estable (ver Figura 8).

***Figura 8**.Detalle mensual del pronóstico, con su intervalo, a referencia simple y la comparación con el mismo mes del año anterior.*



	Pronóstico	Mínimo 80%	Máximo 80%	Referencia simple	Mismo mes año anterior	Variación vs año anterior (%)
Oct 2026	141.2	105.4	176.9	141.1	146.1	-3.4
Nov 2026	132.4	95.6	169.3	130.7	112.5	17.7
Dic 2026	151.1	113.6	188.5	160.4	160.7	-6
Ene 2027	148.4	110.5	186.3	142.3	189.9	-21.8
Feb 2027	126.3	88.1	164.6	120.5	152	-16.9
Mar 2027	123.9	85.4	162.4	118.7	96.8	27.9
Abr 2027	135.8	97.1	174.5	136.3	160.2	-15.2
May 2027	151.6	112.8	190.5	163.6	168.9	-10.2
Jun 2027	127.1	88.1	166.1	114.1	37	244
Jul 2027	143.2	104.2	182.3	138.9	154.2	-7.1
Ago 2027	144.3	105.2	183.5	129.7	147.1	-1.9
Sep 2027	155.5	116.3	194.8	144.5	115.2	35

Nota: La variación de junio de 2027 (+244%) no es representativa: se calcula contra junio de 2026, un mes atípico de solo 37t. Días de paros y bloqueos a nivel nacional.

La implantación se hará en tres fases: **(a) piloto de tres meses**, en que el pronóstico se compara con el método de planificación actual sin reemplazarlo; **(b) uso operativo**, con revisión mensual de los resultados; y **(c) automatización** de los pasos 1 a 3 en un solo programa que no requiera ejecutar el notebook manualmente.

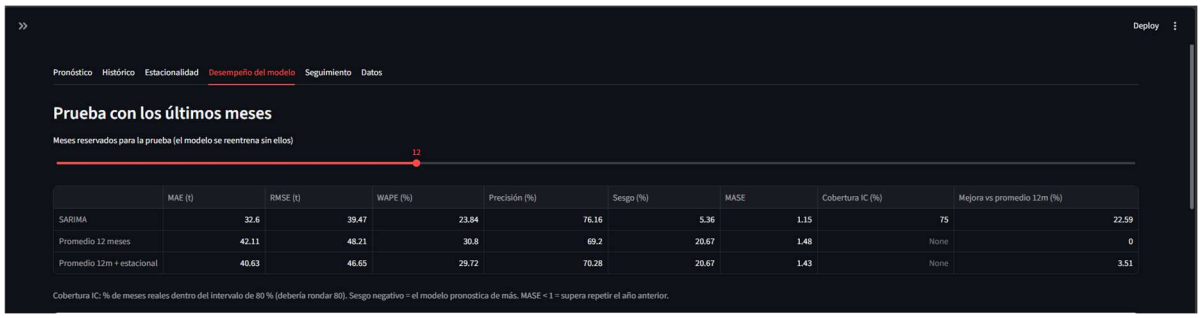
6.2 Plan de monitoreo y mantención

En este punto se evalúa qué fue lo correcto y qué lo incorrecto, qué es lo que se hizo bien y qué es lo que se requiere mejorar.

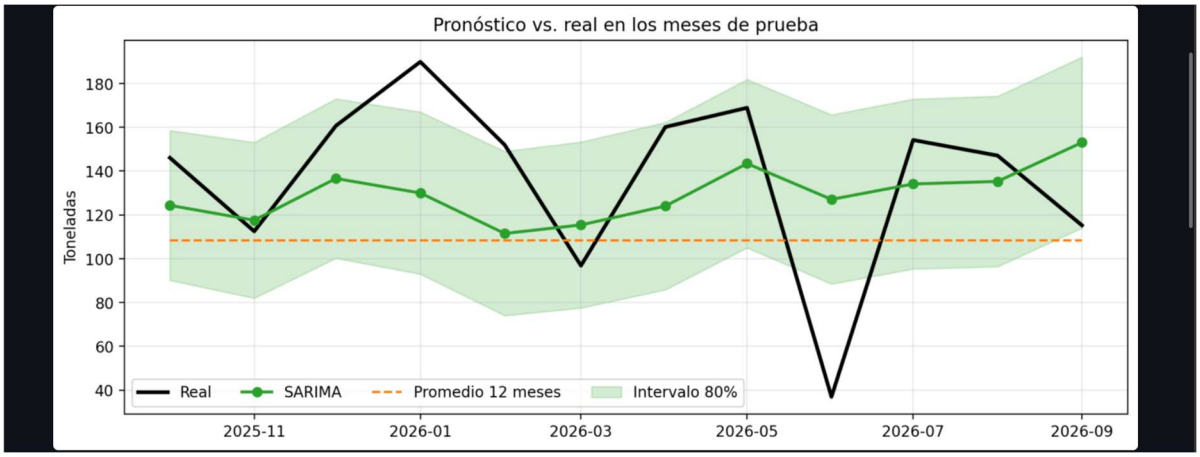
Qué se hizo bien

- Un tratamiento de datos con controles de calidad: cuadre con los totales de cada archivo, verificación del peso por bolsa, revisión de la continuidad en la numeración de las notas y corrección de fechas mal digitadas con base en las ventas vecinas.
- Una prueba con los últimos 12 meses, con el modelo reentrenado sin ellos. El SARIMA alcanzó una precisión de 76% (MAE de 32.6 t) y el intervalo de 80% contuvo el 75% de los meses reales, con un error 22.6% menor al del promedio móvil de 12 meses (ver Figura 9 son dos imágenes separadas).

***Figura 9.** Prueba con los últimos 12 meses: métricas de error del SARIMA frente a los modelos simples, y pronostico contra demanda real.*



	MAE (t)	RMSE (t)	WAPE (%)	Precisión (%)	Sesgo (%)	MASE	Cobertura IC (%)	Mejora vs promedio 12m (%)
SARIMA	32.6	39.47	23.84	76.16	5.36	1.15	75	22.59
Promedio 12 meses	42.11	48.21	30.8	69.2	20.67	1.48	None	0
Promedio 12m + estacional	40.63	46.65	29.72	70.28	20.67	1.43	None	3.51



- Una validación cronológica con 14 cortes en el tiempo y comparación contra modelos simples. El SARIMA obtuvo el menor error (MAE de 27.8 t, WAPE de 19.3%, sesgo de -3.7%) y superó al promedio móvil de 12 meses en 10 de los 14 cortes (ver Figura 10)

Figura 10. *Validación móvil (14 cortes en el tiempo): error promedio de cada modelo y error por fecha de corte.*



- Residuos sin estructura pendiente (Ljung-Box con p = 0.17 y 0.78) e intervalos de confianza para comunicar la incertidumbre (ver Figura 11).

Figura 11. *Diagnóstico del modelo ajustado: parámetros, prueba de Ljung-Box y residuos.*



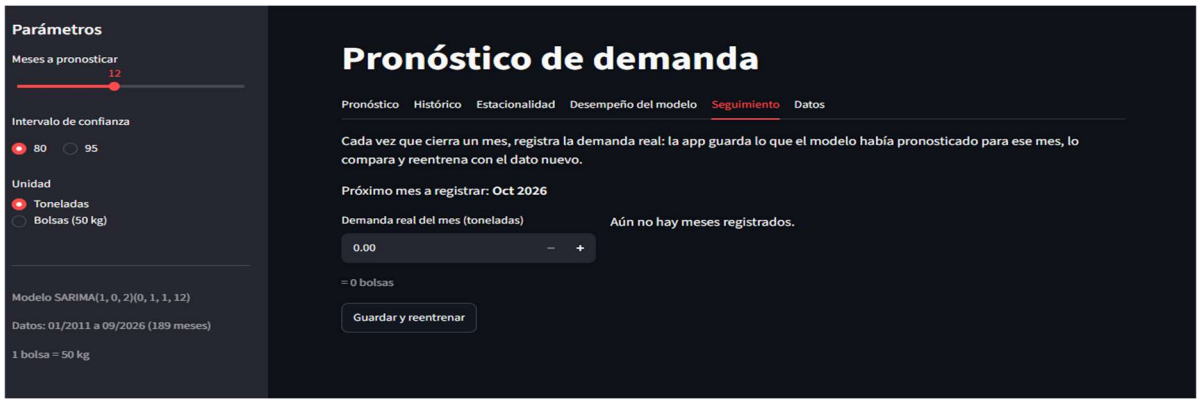
Qué se requiere mejorar

- Los datos de origen tienen errores de digitación (fechas, pesos y nombres de clientes escritos de distintas formas) y totales desactualizados.
- La ventaja del modelo sobre un promedio simple es modesta en promedio (cerca de 4% en la validación móvil) y la precisión mensual está entre 76% y 81%.
- En junio de 2026 la demanda registrada cayó a 37 t, porque entre el 31 de mayo y el 18 de junio no se emitieron notas de venta (la numeración es consecutiva a través de ese período, por lo que no se trata de registros faltantes) [escribe aquí la causa, si la empresa la confirma]. Este mes atípico no pudo ser anticipado por el modelo y explica cerca de un cuarto del error de la prueba con los últimos 12 meses.
- No se incorporaron variables explicativas (precio, número de clientes activos), ni se conoce la causa de la caída de demanda desde 2024.

Monitoreo y mantención

- Cada cierre de mes se revisará la efectividad de las decisiones directamente en el panel de Streamlit, comparando la demanda real con lo pronosticado. La sección de seguimiento registra el mes real, calcula el error, el sesgo acumulado y el porcentaje de meses dentro del intervalo de 80%, para ajustar las estrategias o tomar nuevas decisiones de negocio (ver Figura 12)

Figura 12*. Pestaña "seguimiento": registro mensual de la demanda real. La herramienta esta implementada y aun no tiene meses registrados.*



- **Regla de reentrenamiento:** si tres meses seguidos caen fuera del intervalo de 80%, o el sesgo acumulado supera ±15%, se reentrena el modelo con una ventana más reciente (por ejemplo, desde 2018).
- Se crearán alertas automatizadas para detectar datos inconsistentes: fechas no válidas o de otro año, ventas donde el peso no coincide con las bolsas, diferencias contra el total del archivo, notas duplicadas, saltos en la numeración de las notas, períodos prolongados sin ventas y, sobre todo, que el archivo del mes no se haya cargado. Asimismo, se monitoreará la disponibilidad de la aplicación de Streamlit y el tiempo de respuesta al cargar los gráficos interactivos.
- Se mantendrán bitácoras de los cambios en los datos sensibles del análisis (correcciones manuales de fechas y pesos con número de nota, valor original y valor corregido, y el tratamiento de abril y mayo de 2020 por la pandemia), de cada versión del modelo con sus parámetros y fecha de entrenamiento, y un registro de accesos e interacciones clave en la interfaz, para saber qué vistas y métricas usan más los responsables de planificación.

7. Conclusiones

Se logró construir un modelo de pronóstico de demanda mensual a partir de 19 años de ventas, que estaban separadas en archivos de Excel con estructuras distintas y errores de digitación. El tratamiento de datos permitió unificar aproximadamente 8,300 ventas y construir una serie mensual confiable, expresada en toneladas y convertible a bolsas de 50 kg.

El análisis mostró tres hallazgos principales:

- La demanda pasó por tres etapas: un crecimiento entre 2008 y 2010, una etapa estable en torno a 150 toneladas mensuales hasta 2023, y una baja con mayor volatilidad desde 2024.
- Existe una estacionalidad real, comprobada estadísticamente ($p = 0.001$) pero débil: la fuerza estacional es 0.10 en una escala de 0 a 1, con efectos de hasta ±10% sobre el nivel en los meses extremos. Marzo y junio son los meses más bajos; agosto y septiembre, los más altos (ver Figura 13).

***Figura 13**. Efeto estacional promedio de cada mes sobre el nivel de demanda (Fuerza estacional de 0.10).*



- El nivel reciente de la demanda pesa más que la tendencia histórica: la regresión lineal con tendencia fue el modelo de peor desempeño, porque extrapola el crecimiento de los primeros años.

Pros. El SARIMA es el modelo de mejor desempeño, con residuos limpios e intervalos de confianza útiles para planificar. Su pronóstico coincide con el de un método simple de control (diferencia de 2.4% en el total anual), lo que da robustez al resultado. Además, la aplicación web permite que los responsables de planificación consulten el pronóstico, el histórico y el desempeño del modelo, y actualicen la serie cada mes sin conocimientos de programación.

Contras. La precisión mensual está entre 76% y 81%, y la mejora sobre un promedio móvil simple es modesta. Gran parte de la variación de cada mes depende de pedidos grandes y puntuales, y de eventos como la parada de actividad de junio de 2026, que ningún modelo de series de tiempo anticipa. Además, el modelo no explica por qué bajó la demanda desde 2024, y si esa caída continúa, el pronóstico quedará por encima de lo real.

Como trabajo futuro se propone incorporar variables explicativas (precio por kg, número de clientes activos, concentración de las ventas en los clientes principales), analizar la demanda por cliente o por grupo de clientes y probar un modelo más simple, ya que uno de los parámetros del SARIMA actual no es estadísticamente significativo. Los resultados permitirán elaborar planes de compra y producción con base en el pronóstico y su intervalo, y el seguimiento mensual indicará cuándo es necesario revisar el modelo.

8. Bibliografía

Box, G. E., Jenkins, G. M., Reinsel, G. C., & Ljung, G. M. (2015). *Time series analysis: Forecasting and control* (5.ª ed.). (Wiley, Ed.) Hoboken, NJ: Wiley.

Chapman, P., Clinton, J., Kerber, R., Khabaza, T., Reinartz, T., Shearer, C., & Wirth, R. (2000). *CRISP-DM 1.0: Step-by-step data mining guide.* CRISP-DM Consortium.

Hyndman, R. J., & Athanasopoulos, G. (2021). *Forecasting: Principles and practice* (3.ª ed.). (OTexts, Ed.) Melbourne, Australia: OTexts. Obtenido de https://otexts.com/fpp3/

Hyndman, R. J., & Koehler, A. B. (2006). Another look at measures of forecast accuracy. *International Journal of Forecasting*, 679–688. doi:10.1016/j.ijforecast.2006.03.001

Mason, H., & Wiggins, C. (25 de septiembre de 2010). Obtenido de Dataists: http://www.dataists.com/2010/09/a-taxonomy-of-data-science/

Schröer, C., Kruse, F., & Gómez, J. M. (2021). A systematic literature review on applying CRISP-DM process model. *Procedia Computer Science, 181*, 526–534.

Wirth, R., & Hipp, J. (2000). CRISP-DM: Towards a standard process model for data mining., (págs. 29–39). Manchester, Reino Unido (confírmalo en la portada del PDF).